

Alur dan Narasi Lengkap Penelitian CBR Research Project

Dokumen ini menyajikan narasi menyeluruh mengenai alur, metodologi, proses eksperimen, dan temuan empiris dari penelitian yang diimplementasikan pada berkas

`Program/research_implementation.ipynb`. Seluruh penjelasan disajikan dalam bentuk narasi deskriptif yang mengalir secara berurutan, mulai dari latar belakang klinis, rekayasa data, perancangan sistem penalaran berbasis kasus, evaluasi komparatif terhadap model pembelajaran mesin, hingga analisis mendalam mengenai pengujian data eksternal.

Latar Belakang dan Konteks Penelitian

Penelitian ini berangkat dari kebutuhan penegakan diagnosis penyakit sakit kepala primer, khususnya dalam membedakan antara *Cluster Headache* (kode ICD-X: G44.0) dan *Tension-Type Headache* (kode ICD-X: G44.2). Dalam praktik kedokteran sehari-hari, kedua jenis sakit kepala ini sering kali sulit dibedakan pada tahap awal karena anamnesis sangat bergantung pada penuturan subjektif pasien mengenai lokasi nyeri, sensasi rasa sakit, dan durasi keluhan. Keahlian seorang dokter spesialis saraf dalam mengidentifikasi pola-pola keluhan tersebut merupakan bentuk pengetahuan klinis bernilai tinggi yang perlu didokumentasikan ke dalam suatu sistem pendukung keputusan klinis (*Clinical Decision Support System*).

Untuk membangun sistem kecerdasan buatan pendukung keputusan medis, penelitian ini memadukan dan membandingkan dua filosofi yang berbeda. Pendekatan pertama adalah *Case-Based Reasoning* (CBR), yaitu pendekatan berbasis pengetahuan (*knowledge-driven*) yang meniru cara berpikir kognitif manusia dalam memecahkan masalah baru berdasarkan analogi kemiripan dengan pengalaman kasus-kasus di masa lalu. Pendekatan kedua adalah *Support Vector Machine* (SVM), yaitu algoritma pembelajaran mesin (*data-driven*) yang bekerja dengan cara mencari batas pemisah matematis optimal antar kelas data.

Tantangan terbesar yang dihadapi dalam penelitian ini adalah keterbatasan jumlah data awal (*data scarcity*), di mana rekam medis riil yang tersedia hanya berjumlah 40 pasien. Jumlah data sekecil ini sangat rentan menyebabkan kegagalan belajar pada algoritma statistik (*underfitting*) dan keterbatasan cakupan pengalaman pada basis pengetahuan CBR. Selain itu, pasien di dunia nyata sering kali tidak melaporkan seluruh gejala yang dirasakannya secara lengkap, sehingga sistem dituntut untuk tetap mampu mengenali pola meskipun informasi yang diterima tidak utuh.

Persiapan Lingkungan dan Pembacaan Dataset Primer

Seluruh tahapan eksperimen dijalankan secara terintegrasi dalam satu Jupyter Notebook. Tahap awal dimulai dengan mempersiapkan pustaka-pustaka komputasi ilmiah dalam ekosistem Python, seperti *pandas* dan *numpy* untuk manipulasi data tabel dan matriks, *matplotlib* dan *seaborn* untuk kebutuhan visualisasi, serta modul-modul dari *scikit-learn* untuk pembobotan teks TF-IDF, klasifikasi SVM, dan perhitungan metrik evaluasi. Seluruh jalur direktori kerja diatur secara modular dan relatif terhadap lokasi notebook, sehingga eksperimen dapat dijalankan ulang di komputer mana pun tanpa kendala ketergantungan *path*.

Dataset primer kemudian dimuat dari file `dataset.xlsx`. Karena baris pertama file Excel berisi judul metadata, pembacaan dilakukan mulai dari baris kedua. Dataset ini memuat 40 catatan medis pasien dengan komposisi label diagnosis yang seimbang sempurna, yaitu 20 kasus terdiagnosis G44.0 (*Cluster Headache*) dan 20 kasus terdiagnosis G44.2 (*Tension-Type Headache*). Pemeriksaan kualitas data menunjukkan bahwa tidak terdapat nilai kosong pada kolom-kolom kunci yang digunakan, yaitu kolom label diagnosis (`icd_x`), kolom daftar gejala yang telah dinormalisasi dalam huruf kecil dan dipisahkan tanda titik koma (`normalized_semicolon`), serta kolom kode representasi kasus (`case_codes`).

Eksplorasi Pengetahuan dan Pemetaan Relasi Gejala-Kasus

Sebelum melangkah ke pemodelan, penelitian mengeksplorasi struktur hubungan pengetahuan yang terkandung di dalam dataset. Melalui proses ekstraksi dan pemilahan teks gejala, sistem berhasil memetakan sebanyak 186 gejala klinis unik serta 32 kode kasus unik.

Dari data tersebut, dibangun dua kamus asosiasi yang saling melengkapi. Kamus pertama memetakan setiap gejala klinis ke daftar kode kasus yang pernah berhubungan dengannya, sedangkan kamus kedua memetakan setiap kode kasus ke gejala-gejala yang paling sering muncul bersamanya berdasarkan frekuensi kemunculan tertinggi. Pemetaan ini memberikan gambaran struktural mengenai keterkaitan antar gejala klinis. Selanjutnya, daftar kode kasus pada setiap baris ditransformasikan ke dalam representasi biner multi-hot (*multi-hot encoding*) berukuran 40 baris kali 32 kolom, sehingga setiap kode kasus unik menjadi satu fitur biner tersendiri.

Strategi Pengayaan Pengetahuan via Augmentasi Data (Random Deletion)

Keterbatasan 40 data awal disadari menjadi kendala utama bagi stabilitas model. Oleh karena itu, penelitian menerapkan teknik augmentasi data berbasis *Random Deletion*. Pemilihan metode ini memiliki landasan klinis yang kuat, yaitu menyimulasikan fenomena nyata di mana seorang pasien sering kali lupa atau tidak menceritakan sebagian keluhannya kepada dokter.

Dengan menghapus sebagian gejala secara acak, sistem dipaksa untuk belajar mengenali pola penyakit dari kombinasi sub-gejala yang tidak lengkap.

Secara teknis, setiap gejala pada sebuah kasus diberikan peluang sebesar 15% untuk dihilangkan secara acak. Gejala-gejala yang tidak terhapus kemudian dirangkai kembali menjadi sebuah kasus baru dengan tetap mempertahankan label diagnosis aslinya. Proses augmentasi ini dijalankan sebanyak 4 putaran independen, sehingga dari 40 data awal berhasil dihasilkan 160 kasus sintesis baru. Ketika digabungkan dengan 40 data asli, terbentuklah dataset terpadu berisi 200 kasus rekam medis. Setiap kasus diberi penanda asal-usul data (`asli` , `aug_1` , `aug_2` , `aug_3` , atau `aug_4`) dan disimpan ke dalam file `dataset_augmented.xlsx` . Untuk memastikan seluruh proses dapat direproduksi persis sama di kemudian hari, pengacakan dikunci menggunakan nilai *random seed* 42.

Eksperimen Pemodelan Machine Learning (Support Vector Machine)

Setelah repositori data bertambah menjadi 200 kasus, penelitian melatih model *Support Vector Machine* (SVM) dengan kernel linier untuk melihat seberapa jauh algoritma pembelajaran mesin statistik mampu mengenali pola teks gejala. Gejala pasien ditransformasikan ke dalam representasi vektor TF-IDF dengan kapasitas hingga 5.000 fitur. Data kemudian dibagi menjadi 80% data latih (160 kasus) dan 20% data uji (40 kasus).

Hasil pengujian pada data augmented ini sangat memuaskan, di mana model SVM berhasil meraih tingkat akurasi sebesar 97,50%, dengan nilai *Weighted F1-Score* 0,9750, *Precision* 0,9763, dan *Recall* 0,9750. Dari 40 kasus uji yang dievaluasi, 39 kasus berhasil diprediksi dengan tepat dan hanya satu kasus yang meleset.

Untuk membuktikan secara ilmiah apakah lonjakan performa tersebut benar-benar merupakan kontribusi dari augmentasi data, dilatih model pembandingan (*baseline*) SVM linier dengan konfigurasi yang sama persis, namun hanya menggunakan 40 data asli tanpa augmentasi (dibagi menjadi 32 data latih dan 8 data uji). Hasilnya sangat kontras: model baseline hanya mampu mencatatkan akurasi sebesar 50,00%, dengan *F1-Score* 0,4333 dan *Recall* 0,5000. Akurasi 50% pada klasifikasi biner setara dengan tebakan acak, yang menandakan bahwa model asli mengalami *underfitting* parah akibat minimnya contoh data latih. Perbandingan langsung membuktikan bahwa augmentasi *Random Deletion* berhasil meningkatkan akurasi SVM sebesar 47,50% dan mendongkrak *F1-Score* sebesar 54,17%.

Analisis terhadap koefisien bobot linier pada model SVM teraugmentasi juga berhasil mengungkap sepuluh kata gejala yang paling berpengaruh dalam membedakan diagnosis. Kata-kata seperti *terasa*, *kurang*, *lebih*, *belakang* (yang merujuk pada rasa tegang di bagian belakang kepala atau leher khas sakit kepala tegang), *pusing*, *kemarin*, *alergi*, dan *depan* terbukti menjadi penentu utama batas pemisah klasifikasi pada model SVM.

Pembangunan dan Alur Inferensi Sistem Case-Based Reasoning (CBR)

Tahap berikutnya adalah membangun sistem *Case-Based Reasoning* (CBR) yang memanfaatkan 200 kasus teraugmentasi tersebut sebagai basis pengetahuan (*case base*). Berbeda dengan SVM yang mengabaikan urutan kata, representasi teks pada basis kasus CBR menggunakan pembobotan TF-IDF dengan rentang n-gram unigram dan bigram (1 hingga 2 kata). Pendekatan ini sengaja dipilih agar frasa gabungan gejala medis dua kata yang penting—seperti *nyeri kepala*, *pusing berputar*, atau *leher kaku*—dapat tertangkap sebagai satu kesatuan fitur yang utuh. Matriks basis kasus yang terbentuk memiliki dimensi 200 baris kasus dan 741 fitur n-gram unik.

Sistem CBR dirancang mengikuti siklus penalaran kasus yang transparan dan aman melalui tahapan-tahapan berikut:

Pertama, pada tahap pencarian (*Retrieve*), setiap teks query gejala baru yang dimasukkan diubah ke dalam bentuk vektor, lalu dihitung derajat kemiripannya terhadap seluruh 200 kasus di basis pengetahuan menggunakan rumus *Cosine Similarity*. Sistem menerapkan ambang batas kemiripan (*similarity threshold*) yang ketat, yaitu 0,70, serta membatasi pencarian maksimal pada 5 kasus terdekat (*Top-5 Neighbors*). Hanya kasus-kasus terdahulu yang memiliki nilai kemiripan minimal 70% yang akan ditarik sebagai rujukan.

Kedua, pada tahap penggunaan kembali (*Reuse*), sistem menetapkan prediksi diagnosis menggunakan pemungutan suara berbobot (*weighted majority voting*). Dalam mekanisme ini, setiap kasus rujukan yang lolos ambang batas memberikan suara untuk label diagnosisnya, dengan bobot suara yang sebanding dengan nilai kemiripannya. Diagnosis dengan akumulasi bobot tertinggi dinyatakan sebagai hasil prediksi akhir, disertai dengan perhitungan skor keyakinan (*confidence score*) yang mengukur seberapa dominan konsensus antar kasus rujukan tersebut.

Ketiga, sistem dilengkapi dengan kebijakan keselamatan klinis (*Clinical Abstain Policy*). Apabila pada tahap *Retrieve* tidak ditemukan satu pun kasus di basis pengetahuan yang mencapai nilai kemiripan 0,70, sistem menolak untuk memaksakan tebakan dan mengeluarkan status `TIDAK_TERJAWAB`. Dalam dunia medis, menyatakan tidak tahu ketika bukti tidak cukup meyakinkan jauh lebih aman daripada memberikan diagnosis yang salah.

Fungsi sistem ini kemudian didemonstrasikan menggunakan satu query kasus baru dengan keluhan demam, pusing, buang air besar lembek, tanpa mual muntah, dan tanpa riwayat alergi obat. Sistem berhasil menemukan 4 kasus rujukan dengan tingkat kemiripan di atas 0,70, dan secara meyakinkan menghasilkan prediksi diagnosis G44.0 (*Cluster Headache*) dengan tingkat keyakinan (*confidence*) penuh sebesar 100,00%.

Evaluasi Internal Sistem CBR Menggunakan Leave-One-Out Cross-Validation

Untuk menguji performa CBR secara objektif pada basis kasus 200 sampel, diterapkan metode evaluasi *Leave-One-Out Cross-Validation* (LOO-CV). Metode ini dianggap sebagai standar emas validasi untuk dataset berukuran sedang karena mampu mengeliminasi bias pemilihan data latih dan uji. Proses ini berjalan sebanyak 200 putaran berulang, di mana pada setiap putaran, 1 kasus diambil sebagai bahan uji sementara 199 kasus lainnya berperan sebagai basis kasus rujukan.

Hasil evaluasi LOO-CV menunjukkan performa penalaran yang sangat konsisten:

- Dari 200 kasus yang diuji, sistem berhasil menjawab sebanyak 192 kasus, yang berarti sistem memiliki tingkat cakupan (*coverage*) sebesar 96,0%.
- Sebanyak 8 kasus (4,0%) dinyatakan berstatus `TIDAK_TERJAWAB` karena tidak menemukan pasangan kasus dengan kemiripan mencapai 0,70.
- Yang paling mengesankan, pada 192 kasus yang berhasil dijawab, seluruhnya terprediksi dengan benar sesuai label diagnosis aslinya tanpa ada satu pun kesalahan (192 benar, 0 salah). Hal ini menghasilkan akurasi kondisional (*Conditional Accuracy*) sempurna sebesar 100,00%, dengan nilai *Weighted F1-Score*, *Precision*, dan *Recall* yang seluruhnya mencapai 1,0000.
- Jika dihitung terhadap seluruh 200 kasus (termasuk 8 kasus yang tidak terjawab), akurasi keseluruhan (*Overall Accuracy*) CBR berada pada angka 96,00%.
- Rata-rata jumlah kasus rujukan yang ditarik per query adalah 3,54 kasus, dengan tingkat keyakinan rata-rata sebesar 1,0000. Distribusi kemiripan maksimum juga menunjukkan bahwa mayoritas kasus uji memiliki kemiripan di atas 0,85 dengan kasus pasangannya di basis pengetahuan.

Ketika diperbandingkan secara internal, baik SVM teraugmentasi (akurasi 97,50%) maupun CBR (akurasi keseluruhan 96,00% dan akurasi kondisional 100,00%) membuktikan bahwa pengayaan data berhasil membawa kedua model mencapai performa puncak.

Kemampuan Belajar Mandiri: Demonstrasi Fase RETAIN

Salah satu keunggulan terbesar sistem CBR dibandingkan algoritma pembelajaran mesin konvensional terletak pada kemampuannya mengelola siklus pengetahuan secara berkelanjutan melalui fase retensi (*RETAIN*). Pada model pembelajaran mesin seperti SVM, apabila terdapat data pasien baru yang ingin dipelajari, keseluruhan model beserta parameternya harus dilatih ulang dari awal melalui proses komputasi yang memakan waktu.

Sebaliknya, pada sistem CBR, fase *RETAIN* memungkinkan akuisisi pengetahuan baru secara instan dan inkremental (*incremental learning*). Hal ini dibuktikan melalui sebuah simulasi di mana seorang dokter memvalidasi kasus baru dengan keluhan kepala berdenyut sebelah kanan

disertai mual dan penurunan nafsu makan, dengan diagnosis terkonfirmasi G44.0. Fungsi `cbr_retain` langsung menyisipkan kasus baru tersebut ke dalam tabel basis kasus, sehingga ukuran basis kasus bertambah seketika dari 200 menjadi 201 kasus. Vektor representasi diperbarui secara langsung tanpa perlu pelatihan ulang. Ketika diuji dengan kueri gejala serupa, sistem langsung mempertimbangkan kasus baru tersebut sebagai preseden rujukan. Fleksibilitas ini sangat ideal bagi lingkungan rumah sakit yang setiap hari terus menerima variasi kasus baru dari pasien.

Pengujian pada Data Eksternal Independen (datatesting.xlsx)

Ujian sesungguhnya bagi sebuah sistem kecerdasan buatan klinis adalah ketika dihadapkan pada data riil baru yang benar-benar independen dan belum pernah dilihat sebelumnya selama proses pelatihan maupun augmentasi. Untuk keperluan ini, dilakukan pengujian terhadap berkas `datatesting.xlsx` yang memuat 25 kasus rekam medis pasien rujukan baru, terdiri atas 9 kasus G44.0 dan 16 kasus G44.2.

Model SVM teraugmentasi yang telah dilatih sebelumnya langsung diuji untuk mengklasifikasikan ke-25 kasus tersebut. Hasilnya, SVM berhasil memprediksi 18 kasus dengan benar dan melakukan kesalahan diagnosis pada 7 kasus, menghasilkan tingkat akurasi sebesar 72,00%, dengan *Weighted F1-Score* 0,7255, *Precision* 0,7515, dan *Recall* 0,7200.

Sementara itu, sistem CBR diuji pada ke-25 kasus tersebut menggunakan basis kasus 200 sampel pada ambang batas kemiripan 0,70. Hasil pengujian CBR memperlihatkan fenomena yang sangat menarik:

- Sistem hanya berhasil memberikan jawaban pada 2 kasus (tingkat *coverage* hanya 8,00%).
- Sebanyak 23 kasus lainnya (92,00%) dinyatakan `TIDAK_TERJAWAB` karena nilai kemiripan tertinggi yang ditemukan berada jauh di bawah ambang batas 0,70.
- Namun, pada 2 kasus yang berhasil dijawab tersebut, keduanya diprediksi dengan tepat 100% benar (akurasi kondisional 100,00%).

Analisis Kesenjangan Kosakata dan Pertukaran Etika Klinis

Hasil yang sangat kontras pada pengujian data eksternal tersebut memicu investigasi analitis yang mendalam. Mengapa sistem CBR yang sebelumnya mencatatkan akurasi 100% pada evaluasi internal tiba-tiba menolak menjawab 92% kasus pada data eksternal?

Penyebab utamanya terletak pada **kesenjangan kosakata** (*vocabulary and semantic gap*). Analisis teks menunjukkan bahwa sekitar **63% kata dan frasa gejala** pada berkas data testing eksternal berstatus *Out-of-Vocabulary* (OOV), artinya kata-kata tersebut belum pernah muncul sama sekali di dalam data pelatihan. Perbedaan gaya penulisan antar dokter pemeriksa menjadi

pemicu utama. Dokter pada data pelatihan mencatat gejala dengan istilah-istilah baku seperti *pusing*, *tengkuk tegang*, atau *nyeri kepala sebelah*. Sebaliknya, dokter pemeriksa pada data testing eksternal mencatat keluhan menggunakan variasi ungkapan natural pasien yang sangat beragam, seperti:

- "kliyengan"
- "tengkuk terasa kenceng kenceng"
- "nyeri kepala seperti terikat dibagian belakang"
- "telinga berdering"
- "resume dari RS Sardjito"

Karena metode representasi TF-IDF bekerja murni berdasarkan pencocokan kata leksikal secara persis (*exact lexical matching*), kueri-kueri baru yang menggunakan sinonim atau frasa daerah tersebut gagal mencocokkan kata dengan basis kasus, sehingga skor kemiripannya jatuh mendekati angka nol dan tidak mampu menembus ambang batas 0,70.

Dari temuan ini, muncul perbandingan filosofis yang sangat tajam mengenai etika pendukung keputusan medis antara kedua model:

1. **Model SVM menerapkan prediksi paksa (*forced prediction*)**. SVM tidak memiliki opsi untuk menolak menjawab. Ketika dihadapkan pada kata-kata baru, model tetap memaksakan diri mengeluarkan keputusan berdasarkan posisi titik data relatif terhadap batas pemisah linier global. Akibatnya, meskipun meraih akurasi 72%, model SVM menghasilkan **7 kesalahan diagnosis (tingkat kesalahan 28%)**. Dalam dunia medis, salah mendiagnosis pasien sakit kepala klaster sebagai sakit kepala tegang membawa risiko fatal karena penanganan daruratnya sangat berbeda.
2. **Model CBR mengedepankan etika keselamatan klinis (*clinical safety*)**. Dengan menetapkan batas minimal kemiripan 0,70, sistem CBR memiliki mekanisme penolakan (*abstain option*). Ketika sebuah kasus baru tidak memiliki preseden rujukan yang cukup kuat di masa lalu, sistem dengan jujur menolak berspekulasi dan menyerahkan keputusan kembali kepada dokter spesialis. Pada kasus-kasus yang berhasil dijawab, akurasi terbukti absolut (100%). Hal ini menjadikan CBR sebagai sistem pendukung keputusan yang jauh lebih aman, transparan, dan dapat dipertanggungjawabkan karena tidak pernah memberikan saran tanpa dasar preseden kasus yang meyakinkan.

Penyimpanan Hasil dan Arah Pengembangan Mendatang

Sebagai langkah penutup eksperimen, seluruh riwayat prediksi dari ke-25 kasus data testing eksternal dikonsolidasikan dan diekspor ke dalam berkas `Dataset/hasil_testing.csv`. File arsip ini mencatat secara transparan nomor kasus, label diagnosis sebenarnya, teks gejala lengkap, hasil prediksi dan status benar/salah dari model SVM, serta hasil prediksi, nilai keyakinan, skor kemiripan tertinggi, jumlah kasus rujukan, dan status akhir dari sistem CBR.

Secara keseluruhan, penelitian ini menyimpulkan bahwa metode augmentasi *Random Deletion* terbukti berhasil melipatgandakan performa model dalam mengatasi kelangkaan data rekam medis. Selain itu, sistem CBR terbukti unggul dalam hal transparansi penalaran, kemampuan belajar inkremental tanpa pelatihan ulang, serta jaminan keselamatan klinis melalui kebijakan penolakan prediksi.

Untuk mengatasi kendala kesenjangan kosakata (*vocabulary gap*) yang ditemukan pada data eksternal, arah penelitian di masa depan disarankan untuk memperluas representasi teks dengan mengintegrasikan ontologi medis standar (seperti SNOMED-CT atau kamus sinonim klinis) serta mengganti representasi leksikal TF-IDF dengan model penanaman makna kalimat biomedis (*Clinical Sentence Embeddings*). Dengan cara demikian, sistem akan mampu mengenali bahwa ungkapan "*kliyengan*" memiliki kesamaan makna klinis dengan "*pusing*", sehingga tingkat cakupan jawaban sistem dapat meningkat secara signifikan tanpa mengorbankan standar keselamatan pasien.